



RAPPORT DU MINI PROJET

« Filière : Science de données, Big Data & AI »

PRÉDICTION DE CONSOMMATION D'ÉNERGIE ÉLECTRIQUE

Réalisées par :

- DIDI Aya
- AMAKASSOU Aziza
- AIT HAMOU Sohaila

Encadrée par :

- Pr.EL ATEIF Sara



REMERCIEMENTS

Avant d'entamer la rédaction de ce rapport, nous tenons à exprimer notre profonde gratitude à travers ces lignes.

Nous remercions chaleureusement l'École Nationale Supérieure de l'Intelligence Artificielle et des Sciences des Données Taroudant (ENSIASDT) pour la qualité de l'enseignement qu'elle dispense, ainsi que pour son engagement à nous préparer aux exigences du monde professionnel à travers des expériences concrètes. Cette opportunité nous a permis d'appliquer nos acquis dans un projet réel et enrichissant.

Nous souhaitons également adresser nos plus vifs remerciements à Madame Sara EL ATEIF, notre encadrante durant ce projet, pour son suivi bienveillant, ses conseils pertinents et l'intérêt qu'elle a porté à notre travail. Ses remarques nous ont beaucoup aidés à approfondir nos réflexions et à mener à bien ce projet.



Résumé

Dans un contexte mondial marqué par la nécessité d'une transition énergétique et l'optimisation des ressources, l'équilibre entre la production et la consommation d'électricité est un enjeu critique. Ce rapport présente la conception et la mise en œuvre d'une solution de Machine Learning visant à prédire la consommation électrique avec une haute précision.

L'analyse exploratoire des données a mis en évidence le rôle prépondérant des facteurs climatiques, notamment la température, révélant une saisonnalité marquée avec des pics de consommation critiques en juillet et août, ainsi qu'une volatilité accrue journalière entre 17h00 et 20h00. Notre modèle prédictif atteint une précision de **98%**, transformant ces observations en outil d'aide à la décision.

Les résultats obtenus permettent de formuler des recommandations opérationnelles concrètes : le gel des maintenances durant la période estivale pour maximiser la disponibilité du parc et l'ajustement dynamique des réserves d'énergie en soirée pour pallier les incertitudes. Au-delà de la performance technique, ce projet démontre que l'Intelligence Artificielle est un levier puissant pour garantir la stabilité du réseau, réaliser des économies substantielles et réduire l'empreinte carbone en évitant la surproduction.



Table des matières

REMERCIEMENTS	2
Résumé	3
Table des matières	4
Table de figures	6
Chapitre 1 : Introduction Générale	7
I Contexte du projet	7
II Problématique	7
III Objectifs du projet	8
IV Intérêt de l'étude	8
Chapitre 2 : Analyse Exploratoire des Données (EDA)	9
I Introduction	9
II Présentation du jeu de données	9
III Prétraitement et nettoyage des données	9
IV Analyse temporelle de la consommation	10
V Analyse de la relation entre température et consommation	10
VI Analyse de la distribution de la consommation	11
VII Analyse de la matrice de corrélation	12
VIII Création de nouvelles variables	13
IX Conclusion de l'analyse exploratoire	14
Chapitre 3 : Approche Méthodologique (Modélisation)	15
I Stratégie de Modélisation : Une Approche Incrémentale	15
II Régression Linéaire	15
1. Principe du modèle	16
2. Choix des variables (Features et Target)	16
3. Préparation des données pour la modélisation	16
4. Entraînement du modèle	16
III Random Forest (Forêt Aléatoire)	17
1. Principe du modèle	17
2. Analyse préalable et choix des variables (Features)	17
3. Préparation des données	20



4. Entraînement du modèle	20
IV XGBoost	21
1. Justification et Fondements Théoriques	21
2. Protocole Expérimental et Implémentation	21
3. Architecture et Paramétrage du Modèle	22
Chapitre 4 : Résultats et Comparaison	23
I Test et performance	23
1. Régression Linéaire:	23
2. Random Forest	28
3. XGBoost	29
II Présentation	34
1. Architecture de l'Application (Dashboard).....	34
2. Module de Simulation et d'Alerte	35
3. Module de Transparence et d'Analyse.....	36
4. Recommandations Stratégiques (Décision)	36
Conclusion	38
Biographie	39



Table de figures

Figure 1: Analyse temporelle de la consommation	10
Figure 2: Analyse de la relation entre température et consommation	11
Figure 3: Analyse de la distribution de la consommation.....	12
Figure 4: Analyse de la matrice de corrélation	13
Figure 5: Matrice de corrélation montrant l'impact prépondérant de la température sur la consommation totale	18
Figure 6: Distribution mensuelle de la consommation illustrant le pic critique de Juillet-Août.	19
Figure 7: Distribution mensuelle de la consommation par heure	20
Figure 8: Métriques d'évaluation régression linéaire	23
Figure 9: Évolution temporelle (valeurs réelles vs prédites) de la régression linéaire.....	24
Figure 10: Nuage de points (Réel vs Prédit) de la régression linéaire	24
Figure 11: Graphe des résidus (Résidus vs Valeurs prédites) de la régression linéaire.....	25
Figure 12: Distribution des résidus.....	26
Figure 13: Évolution des résidus dans le temps.....	26
Figure 14: Importance des variables (coefficients de la régression linéaire)	27
Figure 15: Comparaison temporelle entre la consommation réelle et la prédiction du modèle Random Forest	28
Figure 16: Métriques d'évaluation du random forest.....	28
Figure 17: Métriques d'évaluation de XGBoost	29
Figure 18: Distribution des Erreurs de XGBoost.....	30
Figure 19: Corrélation Réel vs Prédit de XGBoost.....	31
Figure 20: figure de Stabilité Temporelle.....	32
Figure 21: comparaison de consommations réelles vs prédits.....	33
Figure 22: importance des variables	34
Figure 23: interface utilisateur (prédiction des modèles).....	35
Figure 24: interface utilisateurs (comparaison des réelles avec predict).....	36



Chapitre 1 : Introduction Générale

I Contexte du projet

L'énergie électrique constitue aujourd'hui le système nerveux de l'économie mondiale et un pilier fondamental du confort moderne. Dans un contexte marqué par la croissance démographique, l'urbanisation rapide et le développement industriel, la demande en électricité ne cesse de croître. Au Maroc, cette réalité est d'autant plus prégnante que le pays s'est engagé dans une transition énergétique ambitieuse, visant à moderniser ses infrastructures et à intégrer davantage de sources renouvelables.

Cependant, l'électricité présente une contrainte physique majeure : elle ne se stocke qu'en quantités limitées et à des coûts élevés. Par conséquent, l'équilibre entre la production (l'offre) et la consommation (la demande) doit être maintenu en temps réel. Cette équation devient complexe face aux aléas climatiques et aux changements de comportements humains, transformant la gestion du réseau électrique en un défi quotidien de haute précision.

C'est précisément pour répondre à ce défi que ce projet s'appuie sur l'Intelligence Artificielle pour anticiper les fluctuations de la demande. Dans une démarche de transparence et de reproductibilité scientifique, l'intégralité du code source de nos modèles ainsi que l'application de déploiement sont mis à disposition en libre accès sur notre dépôt GitHub : https://github.com/ayadidi/Project_ML_Energy_Load_Forecasting.git

II Problématique

La gestion efficace d'un réseau électrique repose sur la capacité à anticiper le futur. Les gestionnaires de réseau font face à une double contrainte critique :

- **La sous-production** : Si la demande dépasse l'offre, le réseau risque l'instabilité, pouvant mener à des délestages (coupures volontaires) voire à un *black-out* généralisé.
- **La surproduction** : Si l'offre dépasse la demande, l'énergie produite est gaspillée. Cela engendre des coûts financiers inutiles (brûler du carburant pour rien) et un impact environnemental négatif (émissions de CO2 évitables).

Le problème central de ce projet peut donc se formuler ainsi : **Comment exploiter les données historiques et météorologiques pour prédire la consommation électrique avec une fiabilité suffisante, afin d'optimiser les décisions de maintenance et de production ?**



III Objectifs du projet

Pour répondre à cette problématique, notre travail s'articule autour de trois objectifs principaux :

1. **Analyse et Compréhension (Data Analysis)** : Explorer les données historiques pour identifier les facteurs influents (température, saisonnalité, horaires) et comprendre les dynamiques de consommation, notamment les pics estivaux et les variations journalières.
2. **Modélisation Prédictive (Machine Learning)** : Concevoir et entraîner un modèle d'Intelligence Artificielle capable de prévoir la demande future avec une précision maximale (visant un score supérieur à 95%).
3. **Aide à la Décision Stratégique** : Traduire les prédictions mathématiques en recommandations opérationnelles concrètes pour la planification des maintenances et la gestion des réserves d'énergie.

IV Intérêt de l'étude

L'intérêt de ce projet dépasse le simple cadre académique pour toucher à des enjeux sociétaux majeurs :

- **Enjeu Économique** : La réduction des marges d'erreur permet de diminuer les coûts d'exploitation et d'éviter les achats d'énergie d'urgence à prix fort.
- **Enjeu Écologique** : En ajustant la production au plus juste, nous participons à la réduction de l'empreinte carbone du secteur énergétique.
- **Enjeu Technique** : Ce projet illustre le passage vers les *Smart Grids* (réseaux intelligents), où la donnée devient un outil de pilotage aussi important que les câbles électriques.

Chapitre 2 : Analyse Exploratoire des Données (EDA)

I Introduction

L'analyse exploratoire des données (Exploratory Data Analysis – EDA) constitue une étape essentielle dans tout projet de modélisation prédictive.

Elle permet de comprendre la structure des données, d'identifier les tendances, les relations entre variables, ainsi que d'éventuelles anomalies, avant la phase de modélisation.

Dans ce chapitre, nous présentons l'analyse exploratoire du jeu de données de consommation électrique utilisé dans ce projet.

II Présentation du jeu de données

Le jeu de données utilisé provient de la plateforme **Kaggle**, intitulé *Power Consumption Prediction Dataset*.

Il contient des mesures de consommation électrique et des données météorologiques enregistrées toutes les 10 minutes, pour trois zones de la ville de Tétouan.

Les principales variables du dataset sont :

- **DateTime** : date et heure de l'enregistrement
- **Temperature** : température ambiante
- **Humidity** : taux d'humidité
- **Wind Speed** : vitesse du vent
- **general diffuse flows** et **diffuse flows** : flux solaires
- **Zone 1, Zone 2, Zone 3** : consommation électrique par zone

Une variable **Totale_Consumption** a ensuite été créée en sommant les consommations des trois zones afin d'obtenir la consommation totale.

III Prétraitement et nettoyage des données

Avant l'analyse, plusieurs étapes de nettoyage ont été réalisées :

- La colonne **DateTime** a été convertie au format date afin de faciliter l'extraction d'informations temporelles.
- Les données ont été vérifiées pour détecter la présence de valeurs manquantes ou incohérentes.
- Aucun problème majeur de valeurs manquantes n'a été identifié.
- Les données ont été préparées pour l'analyse et la modélisation.

Ces étapes garantissent la qualité et la fiabilité des analyses réalisées par la suite.

IV Analyse temporelle de la consommation

Une analyse de l'évolution temporelle de la consommation électrique a été réalisée à partir d'un extrait des données.




Figure 1: Analyse temporelle de la consommation

Cette analyse montre :

- Une variation régulière de la consommation dans le temps
- La présence de cycles journaliers, caractérisés par des pics et des creux de consommation
- Une structure temporelle marquée, justifiant l'utilisation de modèles adaptés aux séries temporelles

Cette observation confirme que la consommation électrique dépend fortement du temps et du moment de la journée.

V Analyse de la relation entre température et consommation

Un nuage de points représentant la température en fonction de la consommation totale a été analysé.




Figure 2: Analyse de la relation entre température et consommation

Les résultats montrent :

- Une relation globale positive entre la température et la consommation
- Une dispersion importante, indiquant que la température seule n'explique pas entièrement la consommation
- La nécessité d'intégrer d'autres variables explicatives, notamment temporelles et historiques

Cette analyse justifie l'utilisation de plusieurs variables explicatives dans le modèle.

VI Analyse de la distribution de la consommation

L'étude de la distribution de la variable **Total_Consumption** permet de mieux comprendre son comportement global.




Figure 3: Analyse de la distribution de la consommation

L'histogramme montre :

- Une consommation majoritairement concentrée autour de certaines plages de valeurs
- Une distribution légèrement étalée, avec quelques valeurs élevées
- L'absence d'anomalies majeures ou de valeurs extrêmes incohérentes

Cette distribution est compatible avec l'utilisation d'un modèle de régression.

VII Analyse de la matrice de corrélation

Cette matrice permet d'identifier le sens (positif ou négatif) et la force de la relation linéaire entre les variables.




Figure 4: Analyse de la matrice de corrélation

- La température présente une corrélation positive modérée avec la consommation totale, ce qui indique que la consommation tend à augmenter lorsque la température augmente.
- L'humidité montre une corrélation négative avec la consommation, suggérant une baisse de la consommation lorsque l'humidité est élevée.
- La vitesse du vent et les flux diffus présentent des corrélations faibles à modérées avec la consommation, indiquant une influence limitée mais non négligeable.
- Une forte corrélation est observée entre les variables general diffuse flows et diffuse flows, ce qui est logique puisqu'elles décrivent des phénomènes solaires proches.

VIII Création de nouvelles variables

Afin d'améliorer la performance du modèle, plusieurs variables ont été créées :

- Variables temporelles extraites de la date : **heure, jour de la semaine, mois, année**
- Représentation cyclique de l'heure à l'aide de **sinus et cosinus**
- Création d'une variable de retard (**Total_Lag1**) représentant la consommation précédente



Ces variables permettent de capturer à la fois la **dimension temporelle** et la **dépendance historique** de la consommation.

IX Conclusion de l'analyse exploratoire

L'analyse exploratoire des données a permis de :

- Comprendre la structure et la qualité du jeu de données
- Identifier des relations importantes entre la consommation, le temps et les conditions météorologiques
- Justifier le choix des variables explicatives et de la variable cible
- Préparer efficacement les données pour la phase de modélisation

Cette étape constitue une base solide pour l'application de modèles de prédiction, notamment la régression linéaire présentée dans le chapitre suivant.

Chapitre 3 : Approche Méthodologique (Modélisation)

I Stratégie de Modélisation : Une Approche Incrémentale

Pour répondre efficacement à la problématique de l'anticipation de la demande électrique, nous n'avons pas appliqué un seul algorithme au hasard. Notre démarche a suivi une stratégie progressive visant à trouver l'équilibre idéal entre interprétabilité et performance pure.

Nous avons testé et comparé trois modèles distincts, chacun répondant à un objectif précis dans notre processus de recherche :

- **La Régression Linéaire (Le "Baseline")** : Nous avons délibérément commencé par une approche simple. L'objectif était de vérifier s'il existait une relation directe et linéaire entre les variables explicatives et la cible (par exemple : confirmer si une augmentation de la température entraîne proportionnellement une hausse de la consommation). Ce modèle nous a servi de point de référence (baseline) pour évaluer la pertinence des modèles plus complexes.
- **Random Forest (La Robustesse)** : Conscients que les phénomènes climatiques et comportementaux humains ne sont pas toujours linéaires, nous sommes montés en puissance avec l'algorithme Random Forest. Ce choix a été motivé par la nécessité de mieux gérer la non-linéarité des données et d'apporter plus de robustesse aux prédictions face à la variabilité des données météorologiques.
- **XGBoost (La "Performance Pure")** : Enfin, nous avons implémenté XGBoost comme l'étape d'optimisation ultime. C'est un algorithme très puissant basé sur le "Gradient Boosting" (arbres de décision séquentiels). Contrairement aux méthodes précédentes, il construit des modèles successifs où chaque nouveau modèle tente spécifiquement de corriger les erreurs commises par les précédents. Ce choix visait à maximiser la précision pour garantir la fiabilité du réseau.

II Régression Linéaire

Dans un premier temps, une régression linéaire a été mise en place afin de constituer un modèle de référence (baseline).

L'objectif principal de ce choix est de disposer d'un modèle simple, interprétable et rapide à entraîner, permettant de vérifier l'existence d'une relation linéaire entre les variables explicatives et la consommation électrique.



1. Principe du modèle

La régression linéaire vise à modéliser la relation entre une variable cible continue et un ensemble de variables explicatives, en supposant une combinaison linéaire de ces dernières.

Elle permet d'analyser l'influence directe de chaque variable sur la consommation électrique et sert de point de comparaison pour les modèles plus complexes testés par la suite.

2. Choix des variables (Features et Target)

La variable cible (*target*) retenue est la **consommation électrique totale (Total_Consumption)**, calculée à partir des consommations des trois zones.

Les variables explicatives (*features*) utilisées incluent :

- des **variables météorologiques** (température, humidité, vitesse du vent, flux diffus),
- des **variables temporelles** extraites de la date (heure, jour de la semaine, mois, année),
- une **variable de retard (Total_Lag1)** représentant la consommation précédente, afin d'intégrer la dépendance temporelle et l'historique de consommation.

Ce choix permet de capturer à la fois l'effet des conditions climatiques, des cycles temporels et du comportement passé du système.

3. Préparation des données pour la modélisation

Afin d'évaluer correctement les performances des modèles de prédiction, les données ont été divisées en deux ensembles distincts.

80 % des observations ont été utilisées pour l'entraînement du modèle, tandis que **20 %** ont été réservées au test.

Cette séparation a été réalisée sans mélange des données, en respectant strictement l'ordre chronologique des observations. Ce choix est essentiel dans le cadre d'une série temporelle, car il permet de reproduire une situation réelle où le modèle est entraîné sur des données passées et évalué sur des données futures.

Ainsi, cette approche permet d'éviter toute fuite d'information et garantit une évaluation plus fiable des performances du modèle.

4. Entraînement du modèle

Le modèle de régression linéaire a été entraîné sur l'ensemble d'apprentissage en utilisant la bibliothèque *scikit-learn*.

Durant cette phase, le modèle apprend les coefficients associés à chaque variable explicative, permettant d'estimer leur contribution relative à la consommation électrique.



III Random Forest (Forêt Aléatoire)

Suite aux résultats du modèle de référence (Régression Linéaire), nous avons opté pour l'algorithme **Random Forest**. Ce choix est motivé par la nécessité de capturer les non-linéarités identifiées lors de l'analyse exploratoire, notamment les pics de consommation soudains et les interactions complexes entre la météo et la demande.

1. Principe du modèle

Le Random Forest est une méthode d'apprentissage ensembliste (Ensemble Learning) basée sur le "Bagging". Contrairement à la régression linéaire qui cherche une équation unique, cet algorithme construit une multitude d'arbres de décision indépendants. Pour effectuer une prédiction, il agrège les résultats de tous les arbres, ce qui réduit la variance et améliore la robustesse face aux données bruitées.

2. Analyse préalable et choix des variables (Features)

Le choix des variables d'entrée repose sur notre analyse exploratoire des données (EDA), qui a mis en évidence les facteurs déterminants de la consommation.

a. Influence des facteurs météorologiques

L'analyse de la corrélation a révélé une dépendance forte entre la température et la consommation, confirmant que le besoin de climatisation est un "driver" majeur.




Figure 5: Matrice de corrélation montrant l'impact prépondérant de la température sur la consommation totale

Comme le montre la figure ci-dessus, la corrélation positive de **0.49** entre la température et la cible (Total_Consumption) justifie l'intégration des variables météo. Le Random Forest est particulièrement adapté ici car il peut isoler les seuils de température critiques (ex: au-dessus de 30°C) mieux qu'une simple régression.

b. Saisonnalité et comportement temporel

L'analyse temporelle a montré une variabilité extrême selon les mois, avec une explosion de la demande en été.




Figure 6: Distribution mensuelle de la consommation illustrant le pic critique de Juillet-Août.

Ce graphique met en évidence la nature non-linéaire de la demande : la consommation n'augmente pas progressivement, elle bondit en **Juillet et Août**. C'est cette complexité structurelle qui rend le Random Forest indispensable, car il est capable de segmenter les décisions spécifiquement pour ces mois critiques, là où un modèle linéaire global échouerait à capturer l'amplitude du pic.

c. Analyse du Cycle Journalier (Heure)

En analysant la moyenne par heure, nous avons identifié le comportement exact du consommateur marocain sur ce dataset.

- Le Creux (Minimum) : À 06h00 du matin. C'est le moment où la demande est la plus faible (les gens dorment encore, l'éclairage public s'éteint).
- La Pointe (Maximum) : À 20h00 précises.

Le pic de consommation nationale n'est pas à midi, mais à 20h. Cela confirme que notre réseau est dominé par l'usage domestique (éclairage, télé, cuisine le soir) plus que par l'industrie.




Figure 7: Distribution mensuelle de la consommation par heure

Alors, l'analyse exploratoire réalisée sur le jeu de données 'Energy Morocco' a révélé une saisonnalité marquée et un cycle journalier typique. Le profil de charge journalier présente une demande minimale à 06h00 et un pic de consommation (Pointe) à 20h00, dicté par les habitudes domestiques. Sur le plan annuel, on observe une double contrainte : une demande élevée en hiver (Décembre) due au chauffage, et une demande quasi équivalente en été (Août) due à la climatisation. Cette structure complexe justifie l'utilisation d'algorithmes non-linéaires.

3. Préparation des données

Afin d'évaluer les performances dans des conditions réalistes :

- Les données ont été divisées chronologiquement : **80 %** pour l'entraînement et **20 %** pour le test.
- Cette séparation stricte (sans mélange aléatoire) permet de vérifier si le modèle est capable de prédire les pics futurs en se basant uniquement sur l'historique appris.

4. Entraînement du modèle

Le modèle a été entraîné via la bibliothèque **scikit-learn** (RandomForestRegressor). Durant cette phase, l'algorithme a appris à combiner les règles de décision basées sur l'heure, le mois et la température pour minimiser l'erreur de prédiction, en s'adaptant spécifiquement aux zones de forte volatilité identifiées lors de l'EDA.

IV XGBoost

1. Justification et Fondements Théoriques

Pour la phase finale de modélisation, notre choix s'est porté sur l'algorithme **XGBoost (eXtreme Gradient Boosting)**. Il s'agit d'une implémentation optimisée et distribuée du framework de *Gradient Boosting*, reconnue pour son efficacité et sa flexibilité dans les compétitions de Data Science et les applications industrielles.

Contrairement au *Random Forest* qui repose sur le principe du "Bagging" (construction d'arbres indépendants en parallèle pour réduire la variance), XGBoost utilise une technique de "Boosting". Cette approche est **séquentielle** : l'algorithme construit une série de modèles faibles (*weak learners*), généralement des arbres de décision peu profonds. Chaque nouvel arbre ajouté à l'ensemble a pour objectif spécifique de corriger les erreurs résiduelles des arbres précédents. Mathématiquement, le modèle cherche à minimiser une fonction de perte objective régularisée en utilisant la descente de gradient. Cette méthode permet de réduire considérablement le biais du modèle tout en contrôlant la variance, offrant ainsi une précision prédictive supérieure pour des séries temporelles complexes.

2. Protocole Expérimental et Implémentation

L'implémentation a été réalisée dans l'environnement Python via la bibliothèque **xgboost**. Afin de garantir une évaluation impartiale de la performance du modèle, nous avons suivi un protocole rigoureux de partitionnement des données :

a. Séparation des Variables

Distinction entre la matrice des caractéristiques (X, incluant les données météorologiques et temporelles) et la variable cible (y, la Consommation Totale).

d. Partitionnement (Train/Test Split)

Nous avons opté pour une répartition classique de Pareto : **80%** du jeu de données pour la phase d'apprentissage (*Training Set*) et **20%** réservés exclusivement à l'évaluation finale (*Test Set*).

e. Reproductibilité

L'échantillonnage a été effectué de manière aléatoire (`shuffle=True`) mais contrôlée par une graine fixe (`random_state=42`). Cela assure que nos résultats sont stables et reproductibles, une condition sine qua non de la démarche scientifique.



3. Architecture et Paramétrage du Modèle

La configuration du régresseur **XGBRegressor** a fait l'objet d'un réglage fin (*fine-tuning*) pour trouver l'équilibre optimal entre capacité d'apprentissage et généralisation. Les hyperparamètres retenus sont les suivants :

a. Hyperparamètres Structurels (Complexité)

- **n_estimators = 1000** : Ce paramètre définit le nombre maximum d'itérations (ou d'arbres) que le modèle peut construire. Un nombre élevé permet au modèle d'affiner ses prédictions, sous réserve d'un contrôle adéquat du sur-apprentissage.
- **max_depth = 6** : La profondeur maximale de chaque arbre a été limitée à 6 nœuds. Cette contrainte est cruciale : elle permet au modèle de capturer des interactions non-linéaires complexes (comme l'effet combiné de l'heure et de la température) tout en empêchant l'arbre de mémoriser le bruit statistique des données d'entraînement.

f. Optimisation et Convergence

learning_rate = 0.05 : Aussi appelé "shrinkage", ce taux d'apprentissage réduit la contribution de chaque nouvel arbre. Une valeur faible (0.05) force le modèle à apprendre plus lentement mais de manière plus robuste, garantissant une meilleure convergence vers le minimum global de l'erreur.

g. Régularisation et Stochasticité (Robustesse)

Afin de renforcer la capacité de généralisation du modèle et d'éviter l'overfitting, nous avons introduit de l'aléatoire dans le processus de construction des arbres :

- **subsample = 0.8** : Pour chaque arbre, le modèle n'utilise qu'un échantillon aléatoire de 80% des données d'entraînement.
- **colsample_bytree = 0.8** : De même, seule une fraction de 80% des variables explicatives est considérée pour chaque arbre. Cette technique permet de décorrélérer les arbres et de rendre le modèle moins sensible à une variable spécifique qui pourrait être bruitée.

h. Stratégie d'Arrêt Précoce (Early Stopping)

early_stopping_rounds = 50 : Nous avons implémenté un mécanisme de surveillance dynamique. Lors de l'entraînement, si l'erreur calculée sur le jeu de validation ne diminue plus pendant 50 itérations consécutives, l'apprentissage est automatiquement stoppé. Cela permet non seulement d'économiser des ressources de calcul, mais surtout de conserver le modèle à son état optimal, juste avant qu'il ne commence à sur-apprendre. Raisons consécutives, économisant ainsi des ressources de calcul.

Chapitre 4 : Résultats et Comparaison

I Test et performance

Pour valider la pertinence de notre approche, nous avons évalué les modèles sur un jeu de test indépendant (20% du dataset), garantissant ainsi que les résultats reflètent la capacité du modèle à généraliser sur de nouvelles données.

1. Régression Linéaire:

a. Métriques d'évaluation :

```
Performance  $R^2$  : 0.9941  
Erreur Moyenne Absolue (MAE) : 736.85 MW  
Erreur Quadratique Moyenne (RMSE) : 1183.61 MW
```

Figure 8: Métriques d'évaluation régression linéaire

Afin d'évaluer la performance du modèle de régression linéaire, plusieurs métriques quantitatives ont été utilisées, notamment le coefficient de détermination R^2 , l'erreur moyenne absolue (MAE) et l'erreur quadratique moyenne (RMSE).

Les résultats obtenus montrent un **coefficient $R^2=0.9941$** , ce qui signifie que le modèle explique **99,41 %** de la variance de la consommation électrique totale. Ce score très élevé indique une excellente capacité explicative du modèle.

L'erreur moyenne absolue (**MAE = 736.85 MW**) montre que, en moyenne, les prédictions du modèle s'écartent de moins de 800 MW par rapport aux valeurs réelles.

De plus, la **RMSE = 1183.61 MW** confirme que les erreurs importantes restent limitées, traduisant une bonne stabilité globale du modèle.

Ces résultats démontrent que la régression linéaire constitue un excellent modèle de référence (baseline) pour la prédiction de la consommation électrique.

b. Analyse des Résidus :

i. Évolution temporelle (valeurs réelles vs prédites)




Figure 9: Évolution temporelle (valeurs réelles vs prédites) de la régression linéaire

Ce graphique compare l'évolution temporelle de la consommation réelle et celle prédite par le modèle sur une période donnée.

L'analyse visuelle montre que les deux courbes se superposent largement, ce qui indique que le modèle suit correctement les tendances globales et les variations de la consommation électrique au cours du temps.

ii. Nuage de points (Réel vs Prédit)




Figure 10: Nuage de points (Réel vs Prédit) de la régression linéaire

Le nuage de points représentant les valeurs réelles en fonction des valeurs prédites montre un fort alignement des points autour de la diagonale $y=x$.

Cette configuration indique une forte concordance entre les prédictions du modèle et les valeurs observées, confirmant ainsi la très bonne précision de la régression linéaire.

iii. Graphe des résidus (Résidus vs Valeurs prédites)




Figure 11: Graphe des résidus (Résidus vs Valeurs prédites) de la régression linéaire

Le graphique des résidus montre que les erreurs sont réparties de manière aléatoire autour de zéro, sans structure particulière ni tendance apparente.

Cette distribution est un indicateur important, car elle montre l'absence de biais systématique dans les prédictions du modèle.

iv. Distribution des résidus




Figure 12: Distribution des résidus

La distribution des résidus suit une **forme proche d'une courbe en cloche, centrée autour de zéro**, ce qui indique que les erreurs sont globalement symétriques et normalement distribuées.

Cela confirme que la régression linéaire respecte bien ses hypothèses statistiques de base.

v. Évolution des résidus dans le temps




Figure 13: Évolution des résidus dans le temps

L'évolution temporelle des résidus montre une stabilité globale des erreurs au fil du temps. Quelques valeurs extrêmes apparaissent ponctuellement, mais elles restent rares, ce qui confirme la robustesse du modèle sur l'ensemble de la période étudiée.

vi. Importance des variables (coefficients de la régression linéaire)




Figure 14: Importance des variables (coefficients de la régression linéaire)

L'analyse des coefficients de la régression linéaire met en évidence l'influence des différentes variables explicatives sur la consommation électrique.

- Les variables temporelles cycliques (Hour_Sin et Hour_Cos) jouent un rôle majeur, tandis que les variables météorologiques ont un impact plus modéré.
- La variable de retard (Lag1) confirme l'importance de l'historique de consommation, soulignant l'intérêt des dépendances temporelles dans la modélisation.

c. Interprétation :

Les résultats obtenus montrent que la régression linéaire fournit des performances très élevées, avec un pouvoir explicatif supérieur à 99 %.

L'intégration de la variable de retard (consommation précédente) joue un rôle clé dans l'amélioration de la précision.

Cependant, malgré ces très bons résultats, la régression linéaire reste limitée dans sa capacité à capturer :

- Les non-linéarités complexes,
- Les pics de consommation brutaux.

Ces limites justifient l'exploration de modèles plus avancés, capables de mieux représenter la complexité réelle du comportement de consommation électrique.

2. Random Forest

i. Comparaison Visuelle : Valeurs Réelles vs Valeurs Prédites

Afin d'apprécier la qualité globale de la prévision, nous avons superposé la courbe de la consommation réelle (en noir) et celle prédite par notre modèle (en vert) sur la période de 48H.




Figure 15: Comparaison temporelle entre la consommation réelle et la prédiction du modèle Random Forest

L'analyse graphique démontre une excellente adéquation entre les deux courbes. Le modèle parvient à :

- **Suivre la tendance globale** : Les variations saisonnières et hebdomadaires sont parfaitement reproduites.
- **Capter les pics** : Contrairement à un modèle linéaire qui aurait "lissé" les extrêmes, le Random Forest réussit à monter haut lors des pics de consommation, ce qui valide son utilité pour la gestion des périodes de tension (été). Le chevauchement quasi-parfait des courbes confirme visuellement la performance élevée du modèle.

ii. Synthèse des performances sur le Test

--- Performance du Modèle (Régression) ---
RMSE (Erreur Moyenne) : 5107.44 MW
 R^2 Score (Précision) : 0.89

Figure 16: Métriques d'évaluation du random forest

Pour quantifier ces observations visuelles, nous avons calculé les métriques de performance standards sur l'ensemble de test.

Le modèle atteint un coefficient de détermination (R^2) de **0.89**. Ce résultat signifie que notre modèle est capable d'expliquer **89 % de la variance** de la consommation électrique. En

d'autres termes, seulement 11 % des variations de la demande restent inexpliquées (bruit aléatoire ou variables manquantes).

Cette performance valide l'approche choisie : le passage d'une régression linéaire simple à un modèle non-linéaire (Random Forest) a permis de capturer la complexité du réseau électrique marocain avec une précision suffisante pour un déploiement industriel.

3. XGBoost

a. Métriques d'évaluation




Figure 17: Métriques d'évaluation de XGBoost

Nous avons comparé les performances à l'aide de trois indicateurs clés : le R^2 Score (coefficient de détermination), le RMSE (Erreur Moyenne Quadratique) et le MAE (Erreur Absolue Moyenne).

Comme le montre la figure ci-dessus, le modèle XGBoost atteint des performances remarquables sur les données de test :

- **R^2 Score : 0.9836.** Le modèle explique 98,4% de la variance de la consommation électrique, prouvant sa capacité à capturer la quasi-totalité des phénomènes (météo, horaires, saisonnalité).
- **RMSE : 2189.39 MW.** Cette erreur quadratique reste faible par rapport aux pics de consommation (dépassant 100 000 MW), indiquant que les grandes erreurs sont pénalisées et maîtrisées.
- **MAE : 1589.38 MW.** En moyenne, l'écart entre la prédiction et la réalité est inférieur à 1600 MW, soit une marge d'erreur minime (~1.5%).

b. Analyse des Résidus et Fiabilité

L'analyse statistique des erreurs (résidus) est cruciale pour confirmer que le modèle est sain et non biaisé.

i. Distribution des Erreurs




Figure 18: Distribution des Erreurs de XGBoost

L'histogramme des résidus montre une distribution en cloche parfaite (Gaussienne), centrée rigoureusement sur zéro.

- **Absence de Biais** : La moyenne des erreurs étant nulle, le modèle ne souffre d'aucune tendance structurelle à surestimer ou sous-estimer la demande.
- **Symétrie** : L'équilibre parfait de la courbe indique que le modèle traite les pics et les creux avec la même efficacité.

ii. Corrélation Réel vs Prédit




Figure 19: Corrélation Réel vs Prédit de XGBoost

Le graphique de dispersion "Précision : Réel vs Prédit" révèle un alignement dense des points le long de la diagonale $y=x$.

- La linéarité est conservée sur toute la plage de valeurs (de 40 000 à 120 000 MW), confirmant que le modèle est robuste aussi bien en période creuse (nuit) qu'en période de pointe.

iii. Stabilité Temporelle




Figure 20: figure de Stabilité Temporelle

Le graphique "Erreur du modèle par Heure" confirme la stabilité des prédictions tout au long de la journée (0h - 23h).

- La médiane des erreurs reste proche de 0 pour chaque heure.
- On note une légère augmentation de la variance (écart interquartile) entre **17h et 21h**. Cela s'explique par la nature plus aléatoire du comportement humain en soirée (retour au domicile, utilisation imprévisible des appareils électroménagers), contrairement aux heures de bureau ou de nuit qui sont plus régulières.

c. Interprétation et Facteurs d'Influence

i. Capacité de Capture des Pics




Figure 21: comparaison de consommations réelles vs prédits

L'analyse du zoom temporel sur 100 échantillons met en évidence la réactivité du modèle. La courbe rouge (Prédiction XGBoost) épouse parfaitement la courbe bleue (Réal), y compris lors des changements brutaux de consommation. Contrairement à des modèles plus simples qui ont tendance à "lisser" les résultats, XGBoost capture la volatilité nécessaire à la gestion d'un réseau électrique instable.

ii. Importance des Variables (Feature Importance)




Figure 22: importance des variables

L'analyse des variables les plus influentes valide nos hypothèses physiques :

- **Température (Score ~9718)** : C'est de loin le facteur le plus déterminant, confirmant l'impact massif du chauffage et de la climatisation sur le réseau électrique.
- **Humidité (Score ~8173)** : Elle joue un rôle clé dans la sensation thermique ("ressenti"), influençant directement l'usage des climatiseurs.
- **Heure (Score ~7595)** : Essentielle pour modéliser les cycles de vie humains (activité vs sommeil).

II Présentation

La finalité de ce projet n'est pas seulement de produire un modèle performant, mais de fournir un outil opérationnel aux gestionnaires du réseau électrique. Nous avons donc développé une interface utilisateur interactive (Dashboard) permettant de visualiser les prédictions en temps réel et de simuler différents scénarios climatiques.

1. Architecture de l'Application (Dashboard)

L'application a été développée en Python à l'aide du framework **Streamlit**. Ce choix technologique permet de transformer rapidement nos modèles de Machine Learning

(XGBoost, Random Forest, Régression) en une application web accessible, sans nécessiter de compétences avancées en développement web de la part des utilisateurs finaux.

L'interface se divise en deux volets fonctionnels majeurs : la simulation prédictive et l'analyse comparative.

2. Module de Simulation et d'Alerte

La première fonctionnalité est un "Simulateur de Charge". Comme illustré dans la figure ci-dessous, l'utilisateur dispose d'un panneau de contrôle latéral lui permettant de modifier les paramètres influents :

- **Paramètres Temporels** : Date et Heure (pour capturer la saisonnalité et les pics de soirée).
- **Conditions Météo** : Température, Humidité, Vitesse du vent et Flux solaires.




Figure 23: interface utilisateur (prédiction des modèles)

Fonctionnement du module :

Une fois les paramètres saisis, le système interroge simultanément les trois modèles entraînés.

Affichage Multi-Modèles : Le dashboard présente les prédictions de XGBoost, Random Forest et de la Régression Linéaire côte à côte. Cela permet au décideur de voir le consensus entre les modèles.

Système de "Feu Tricolore" : Nous avons intégré une logique métier pour traduire les mégawatts (MW) en état du réseau :

- **Verte (Situation Excellente)** : Consommation < Seuil critique (ex: 69,000 MW). Le réseau est sûr.
- **Orange/Rouge (Alerte)** : Si la prédiction dépasse la capacité de production, une alerte visuelle prévient l'opérateur de risque de délestage.

Sur l'exemple ci-dessus, pour une température de 14.9°C à 14h15, le modèle XGBoost prédit une consommation de **63,710 MW**, classée en zone "Verte".

3. Module de Transparence et d'Analyse

Pour qu'un système d'IA soit accepté par des industriels, il ne doit pas être une "boîte noire". L'onglet "Analyse et Transparence" permet de visualiser le comportement dynamique des modèles sur une fenêtre de temps glissante (ajustable via un curseur, ici 150 heures).




Figure 24: interface utilisateurs (comparaison des réelles avec prédit)

Ce graphique joue un rôle de validation continue :

- Il permet de vérifier visuellement que la courbe rouge (XGBoost) suit fidèlement la courbe bleue (Réel).
- Il met en évidence les limites de la Régression Linéaire (courbe jaune) qui a tendance à être en retard (effet de "Lag") lors des changements brusques, justifiant ainsi notre choix de privilégier XGBoost pour le pilotage en temps réel.

4. Recommandations Stratégiques (Décision)

Grâce à la visibilité offerte par ce modèle prédictif, nous formulons trois recommandations majeures pour la gestion du réseau national :

a. Planification de la Maintenance (Saisonnalité) :

Le modèle confirme que les pics extrêmes surviennent en Été (Juillet-Août due à la climatisation).



Décision : Instaurer un "Gel des Maintenances" strict durant l'été. Les révisions des centrales doivent être programmées exclusivement en Avril-Mai (période creuse identifiée par le modèle) pour garantir 100% de disponibilité lors des pics de chaleur.

d. Gestion de la Pointe du Soir (Comportemental) :

L'analyse horaire montre un pic systématique entre 19h et 21h.

Décision : Mise en place d'une tarification incitative (Heures Creuses / Heures Pleines) pour décourager l'usage des appareils énergivores sur ce créneau spécifique et lisser la courbe de charge.

e. Actions Préventives (Climatique) :

La température étant le facteur n°1 (Feature Importance), une canicule prévue à J+3 par la météo doit déclencher une pré-alerte.

Décision : Campagnes de sensibilisation au nettoyage des filtres de climatisation avant l'été (un filtre encrassé augmente la consommation) et préparation des sources d'énergie d'appoint dès que la température prévue dépasse 30°C.

Conclusion

Au terme de ce projet consacré à la **prévision de la consommation d'énergie électrique**, nous avons pu répondre à une problématique industrielle critique : comment garantir la stabilité du réseau national tout en optimisant les coûts de production face aux aléas climatiques.

Notre démarche méthodologique, allant de l'analyse exploratoire des données à la modélisation avancée, nous a permis de comparer plusieurs approches. Si la Régression Linéaire a fourni une base de référence, c'est l'algorithme **XGBoost** qui s'est imposé comme la solution la plus robuste. Avec un score de précision **R² supérieur à 98%** et une erreur moyenne maîtrisée, ce modèle a démontré sa capacité à anticiper finement les pics de consommation, notamment ceux liés aux vagues de chaleur estivales et aux activités domestiques en soirée.

Au-delà de la performance algorithmique, la valeur ajoutée de ce projet réside dans son **opérationnalité**. Le développement d'un tableau de bord (Dashboard) interactif transforme ces prédictions mathématiques en un véritable outil d'aide à la décision. Il offre aux gestionnaires du réseau la visibilité nécessaire pour :

- Planifier les maintenances durant les périodes creuses (printemps).
- Anticiper les risques de délestage lors des pics critiques.
- Adapter la production en temps réel pour éviter le gaspillage énergétique.

Finalement, ce projet illustre comment la Science des Données peut servir des enjeux majeurs. En ajustant la production au plus juste des besoins réels, nous contribuons non seulement à l'efficacité économique du secteur énergétique, mais aussi à la préservation de l'environnement en réduisant l'empreinte carbone liée à la surproduction inutile.

Biographie

Afin de garantir la transparence de notre démarche scientifique et la reproductibilité de nos résultats, l'ensemble des ressources utilisées et produites dans le cadre de ce projet sont référencées ci-dessous.

1. Jeu de Données (Dataset)

- Power Consumption Prediction Dataset (Kaggle) :

Source primaire de nos données, contenant les historiques de consommation électrique et les relevés météorologiques (température, humidité, vent, flux solaires) de la ville de Tétouan, enregistrés par intervalles de 10 minutes.

- URL : <https://www.kaggle.com/datasets/ruchikakumbhar/power-consumption-prediction-dataset?resource=download>
-

2. Documentation Technique

- Documentation Officielle XGBoost :

Référence technique utilisée pour le paramétrage avancé de notre modèle (hyperparamètres, régularisation et gestion de l'arrêt précoce).

- URL : <https://xgboost.readthedocs.io/>
-

3. Code Source et Déploiement

- Dépôt GitHub du Projet :

Ce dépôt centralise l'intégralité du travail technique réalisé par l'équipe. Il comprend :

- Les **Notebooks Jupyter** pour l'Analyse Exploratoire (EDA) et l'entraînement des modèles.
- Les scripts de **pré-traitement** des données (Data Cleaning).
- Le code source de l'application **Streamlit** (Dashboard de prédiction).
- URL : <https://github.com/ayadidi/Project ML Energy Load Forecasting.git>